

# Explorando o Potencial do Aprendizado Federado na Análise de Motores Elétricos

Orientador: Prof. Rodrigo Cesar Pedrosa Silva

23 de novembro de 2023

## Resumo

Motores elétricos desempenham um papel fundamental em várias aplicações, afetando diretamente a eficiência e a sustentabilidade energética. O projeto em questão visa investigar o uso do aprendizado federado na criação de modelos de aprendizado de máquina para a análise de motores elétricos. Devido à natureza sensível dos dados envolvidos, o aprendizado federado permite que vários clientes colaborem na construção de um modelo central sem compartilhar dados brutos. Os objetivos incluem testar diferentes modelos de aprendizado federado, identificar desafios técnicos e analisar a eficiência do processamento dos dados. A relevância deste projeto reside no potencial que esta tecnologia tem para a criação de modelos de aprendizado federado de grande porte que por sua vez podem acelerar o processo de projeto de análise de motores elétricos. As atividades envolvem revisão bibliográfica, desenvolvimento de modelos, treinamento, avaliação de desempenho e documentação. O projeto busca contribuir para a indústria de motores elétricos e promover pesquisas futuras em aprendizado federado e engenharia elétrica.

## Palavras-chave

Aprendizado Federado, Aprendizado de Máquina, Motores Elétricos, Eficiência Energética

## 1 Introdução

Motores elétricos são componentes cruciais em diversas aplicações industriais e de consumo, e sua eficiência e confiabilidade têm impactos diretos na sustentabilidade e no desempenho energético. A inovação e o desenvolvimento desses sistemas, com complexidade crescente ao longo do tempo, têm sido apoiados cada vez mais por algoritmos de aprendizado de máquina (ML) [6, 4, 5].

Motores elétricos, contudo, variam grandemente em termos de design, aplicação e condições operacionais [6, 1]. Assim, para a construção de um modelo de

aprendizado de máquina amplamente útil, uma base de dados rica e de grande porte se faz necessária. Adquirir estes dados, entretando, é uma tarefa difícil. Os portadores de tais dados são, em geral, empresas que trabalham com o projeto de motores elétricos. Por motivos óbvios, estes não podem compartilhar informações sobre produtos que estão em desenvolvimento.

Neste contexto, surge o Aprendizado Federado (FL) [8]. O FL permite que um modelo seja criado com informações de vários clientes sem que os dados brutos sejam compartilhados. Cada cliente só precisa indicar como ele gostaria que o modelo fosse atualizado e um agregador se encarrega de combinar as orientações de cada cliente para construir um modelo único [8, 7].

Isso pode ser aproveitado na indústria de manufatura em cenários de colaboração interempresarial e intraempresarial [2]. Na colaboração intraempresarial, vários departamentos ou equipes dentro da mesma empresa podem trabalhar juntos usando FL para construir e treinar modelos, melhorando a eficiência e precisão do processo de manufatura. Na colaboração interempresarial, várias empresas podem trabalhar juntas para treinar um modelo global usando seus dados locais, mantendo-os privados, resultando em um modelo preciso e eficiente.

Portanto, este projeto busca investigar como o aprendizado federado pode ser empregado para reunir informações de diversas fontes, preservando a segurança e a privacidade dos dados, e como essa abordagem impacta na qualidade e na precisão dos modelos de aprendizado de máquina desenvolvidos para motores elétricos. Através desta pesquisa, esperamos fornecer uma avaliação detalhada das capacidades e limitações do aprendizado federado nesse campo específico, oferecendo uma base sólida para futuros trabalhos que possam expandir e aplicar esses modelos de forma prática e inovadora.

## 2 Objetivos

### 2.1 Objetivo Geral

O objetivo central deste projeto é investigar e avaliar a viabilidade do uso do aprendizado federado na criação de modelos de aprendizado de máquina para o desempenho de motores elétricos. Isso inclui a análise da eficácia do aprendizado federado em lidar com dados distribuídos e a sua capacidade de gerar modelos precisos e confiáveis para estas aplicações específicas.

### 2.2 Objetivos Específicos

1. Testar e Comparar Modelos de Aprendizado Federado: Desenvolver e testar diferentes modelos de aprendizado de máquina dentro da arquitetura de aprendizado federado, comparando-os em termos de precisão, eficiência e praticidade. Este objetivo visa entender como diferentes abordagens de modelagem se comportam em um ambiente de aprendizado federado.

2. Identificar Desafios e Limitações: Identificar os principais desafios, limitações e barreiras técnicas associadas à implementação do aprendizado federado para modelos de desempenho de motores elétricos. Isso inclui questões como a gestão de dados distribuídos, a eficiência computacional e a integridade dos dados.
3. Analisar a Eficiência da Coleta e Uso de Dados: Avaliar como a coleta e o uso de dados de diferentes fontes (como diferentes tipos de motores elétricos e condições operacionais variadas) impactam a eficácia dos modelos gerados pelo aprendizado federado. O foco será entender se o aprendizado federado pode ser eficiente em ambientes com alta diversidade e volume de dados.
4. Documentar e Disseminar Conhecimentos e Resultados: Documentar os processos, metodologias, resultados e conclusões obtidas durante o projeto, visando fornecer um guia ou referência para futuras pesquisas e aplicações práticas no campo de motores elétricos e aprendizado federado.

Este projeto, portanto, se concentra principalmente na investigação exploratória e técnica sobre a aplicabilidade e eficácia do aprendizado federado em um contexto específico, estabelecendo uma base sólida para futuras iniciativas que possam expandir a utilização destes modelos na prática.

### 3 Justificativa/Relevância

O projeto em questão, focado na aplicação do aprendizado federado na modelagem de desempenho de motores elétricos, representa uma iniciativa de ponta na interseção da inovação tecnológica e da inteligência artificial. A escolha do aprendizado federado, uma fronteira emergente na IA [3, 7], não só destaca o caráter inovador do projeto, mas também responde às crescentes preocupações com a privacidade e segurança dos dados. Permitindo que os dados permaneçam em seus locais de origem.

Além disso, esta abordagem é particularmente pertinente em contextos como o da indústria de motores elétricos, onde os dados estão distribuídos por diversas localidades e entidades que lidam com informações sensíveis e proprietárias. Este projeto não só visa aprimorar a eficiência e a precisão dos modelos de desempenho de motores elétricos, mas também tem o potencial de influenciar positivamente o consumo de energia e reduzir as emissões de carbono, dado o papel crucial que os motores elétricos desempenham em muitos setores.

A relevância do projeto estende-se à contribuição para a indústria de motores elétricos, oferecendo insights que podem levar a melhorias significativas no processo de projeto e análise. Além disso, o projeto promete contribuir significativamente para a literatura acadêmica e para o setor de IA, especialmente nas áreas de aprendizado federado e sua aplicação na engenharia elétrica, fomentando pesquisas futuras e desenvolvimentos tecnológicos.

Em resumo, este projeto não apenas busca uma nova aplicação tecnológica promissora, mas também atende a necessidades práticas e estratégicas no âmbito da indústria de motores elétricos e do campo mais amplo da inteligência artificial, alinhando-se com as tendências globais de inovação, sustentabilidade e segurança de dados.

## 4 Atividades/Metodologias

1. Revisão Bibliográfica e Teórica: Realizar uma revisão abrangente da literatura existente sobre aprendizado federado, modelos de aprendizado de máquina aplicados a motores elétricos e desafios associados à modelagem de dados distribuídos.
2. Desenvolvimento da Arquitetura de Aprendizado Federado: Identificar fontes de dados apropriadas, garantindo uma variedade de tipos de motores elétricos e condições operacionais.
3. Configuração do Ambiente: Configurar um ambiente de teste simulado ou real para o aprendizado federado, assegurando a integração adequada das fontes de dados.
4. Desenvolvimento de Modelos: Criar modelos iniciais de aprendizado de máquina apropriados para a análise de desempenho de motores elétricos.
5. Treinamento dos Modelos: Executar o treinamento dos modelos em um ambiente de aprendizado federado, ajustando os parâmetros conforme necessário para otimizar a performance.
6. Avaliação de Desempenho: Avaliar o desempenho dos modelos em termos de precisão, eficiência e robustez.
7. Comparação com Modelos Centralizados: comparar os resultados obtidos com aqueles de modelos centralizados tradicionais para avaliar as vantagens e desvantagens do aprendizado federado.
8. Documentação: Preparar um relatório detalhado incluindo metodologia, experimentação, análise de resultados e conclusões.
9. Avaliação de Impacto e Recomendações: Avaliar o potencial impacto da implementação do aprendizado federado em ambientes de projeto de motores elétricos. Fornecer recomendações para pesquisas e aplicações futuras com base nas descobertas e experiências do projeto.

## Referências

- [1] Issah Ibrahim, Rodrigo Silva, M. H. Mohammadi, Vahid Ghorbanian, and David A. Lowther. Surrogate models for design and optimization of inverter-

- fed synchronous motor drives. *IEEE Transactions on Magnetics*, 57(6):1–5, 2021.
- [2] Farzana Islam, Ahmed Shoyeb Raihan, and Imtiaz Ahmed. Applications of federated learning in manufacturing: Identifying the challenges and exploring the future directions with industry 4.0 and 5.0 visions, 2023.
  - [3] Peter Kairouz, H. Brendan McMahan, Brendan Avent, Aurélien Bellet, Mehdi Bennis, Arjun Nitin Bhagoji, Kallista Bonawitz, Zachary Charles, Graham Cormode, Rachel Cummings, Rafael G. L. D’Oliveira, Hubert Eichner, Salim El Rouayheb, David Evans, Josh Gardner, Zachary Garrett, Adrià Gascón, Badih Ghazi, Phillip B. Gibbons, Marco Gruteser, Zaid Harchaoui, Chaoyang He, Lie He, Zhouyuan Huo, Ben Hutchinson, Justin Hsu, Martin Jaggi, Tara Javidi, Gauri Joshi, Mikhail Khodak, Jakub Konečný, Aleksandra Korolova, Farinaz Koushanfar, Sanmi Koyejo, Tancrède Lepoint, Yang Liu, Prateek Mittal, Mehryar Mohri, Richard Nock, Ayfer Özgür, Rasmus Pagh, Hang Qi, Daniel Ramage, Ramesh Raskar, Mariana Raykova, Dawn Song, Weikang Song, Sebastian U. Stich, Ziteng Sun, Ananda Theertha Suresh, Florian Tramèr, Praneeth Vepakomma, Jianyu Wang, Li Xiong, Zheng Xu, Qiang Yang, Felix X. Yu, Han Yu, and Sen Zhao. Advances and open problems in federated learning. *Foundations and Trends in Machine Learning*, 14(1–2):1–210, 2021.
  - [4] Arbaaz Khan, Vahid Ghorbanian, and David Lowther. Deep learning for magnetic field estimation. *IEEE Transactions on Magnetics*, 55(6):1–4, 2019.
  - [5] Maria Raluca Raia, Sebastian Ciceo, Fabien Chauvicourt, and Claudia Martis. Multi-attribute machine learning model for electrical motors performance prediction. *Applied Sciences*, 13(3), 2023.
  - [6] Rodrigo César Pedrosa Silva, Tanvir Rahman, Mohammad Hossain Mohammadi, and David Alister Lowther. Multiple operating points based optimization: Application to fractional slot concentrated winding electric motors. *IEEE Transactions on Industrial Electronics*, 65(2):1719–1727, 2018.
  - [7] Mang Ye, Xiuwen Fang, Bo Du, Pong C. Yuen, and Dacheng Tao. Heterogeneous federated learning: State-of-the-art and research challenges. *ACM Comput. Surv.*, 56(3), oct 2023.
  - [8] Chen Zhang, Yu Xie, Hang Bai, Bin Yu, Weihong Li, and Yuan Gao. A survey on federated learning. *Knowledge-Based Systems*, 216:106775, 2021.